FIAP · GLOBAL SOLUTION 2026.2 · CITIZENTECH

AlertaBairro: detecção de alagamentos em vias urbanas com YOLO11

Componente de visão computacional da plataforma AlertaBairro

Disciplina: Applied Computer Vision · **Atividade:** Enxergando o mundo real

Professores: Arnaldo Viana e Paulo Rodrigues

Curso: Engenharia de Software, 4º ano · **Turma:** 4ESPX

Integrantes

Nome completo	RM
Victor Camargo Maciel	98384
Geovanna Silva Cunha	97736
Pedro Emereci Gava	551043
Bianca Carvalho Dancs Firsoff	551645

Repositório: https://github.com/(inserir-link-do-repositorio)

Vídeo de demonstração: (inserir link do vídeo)

Resumo

Em dias de chuva intensa, moradores de São Paulo têm dificuldade para obter informações locais e confiáveis sobre alagamentos. O AlertaBairro é uma plataforma colaborativa que reúne dados públicos e relatos de moradores em um mapa. Este trabalho desenvolve o componente de visão computacional do produto: um detector de água acumulada em vias urbanas, usado para verificar automaticamente as fotos enviadas nos relatos e agilizar a moderação. Utilizou-se um conjunto público do Roboflow Universe com 199 imagens, uma classe (water_logging) e licença CC BY 4.0, ampliado por augmentation para 435 imagens de treino. Foram treinadas duas arquiteturas da família YOLO11, nano e small, no Google Colab com GPU T4 e semente fixa para reprodutibilidade. O YOLO11n obteve mAP50 de 0,275 e identificou alagamento em 56% das imagens de validação; o YOLO11s, 3,6 vezes maior, obteve mAP50 de 0,288, mas identificou alagamento em apenas 44% delas. Em vídeo, o YOLO11n processou 18,2 quadros por segundo e sinalizou alagamento em 92% dos quadros, o que demonstra operação em tempo real. Os resultados indicam que o limite atual está nos dados, e não na capacidade do modelo: há poucas imagens, nenhum exemplo negativo e anotações por caixas para uma região sem forma definida. Como próximos passos, propõem-se a coleta de imagens de ruas de São Paulo, a inclusão de exemplos negativos e a migração para segmentação de instâncias.

Objetivo

Treinar e avaliar um modelo de detecção de objetos capaz de identificar água acumulada em vias urbanas, em imagens e vídeos e em tempo real, para validar automaticamente as fotos enviadas pelos moradores na plataforma AlertaBairro.

1. Introdução

Em São Paulo, chuvas intensas transformam ruas em pontos de alagamento em poucos minutos. Para quem precisa se deslocar, trabalhar ou abrir o comércio, a informação existe, mas está espalhada: dados de chuva, registros históricos de ocorrências e relatos informais ficam em fontes diferentes e nem sempre mostram o que acontece em uma rua específica.

O AlertaBairro responde a esse problema com uma plataforma web que reúne dados públicos e relatos dos moradores em um mapa. Os relatos comunitários são a fonte mais próxima da realidade de cada rua, mas trazem um desafio: é preciso saber se a ocorrência relatada é verdadeira antes de exibi-la a outros moradores. Revisar cada foto manualmente não escala em um dia de temporal, justamente quando o volume de relatos é maior.

Este trabalho desenvolve o componente de visão computacional que resolve essa etapa: um modelo de detecção de objetos que identifica água acumulada em vias a partir da foto enviada pelo morador. Quando o modelo detecta alagamento, o relato recebe o selo de verificado por imagem e pode ser priorizado; quando não detecta, o relato segue para revisão humana. O modelo apoia a moderação, mas não a substitui, e não substitui os alertas oficiais da Defesa Civil.

2. Explicação técnica das ferramentas

2.1 YOLO11 (Ultralytics)

O YOLO (You Only Look Once) é uma família de detectores de um único estágio: a imagem passa uma única vez pela rede, que prevê ao mesmo tempo a posição das caixas delimitadoras e a classe de cada objeto. Essa arquitetura é a escolha natural para tempo real, porque evita a etapa separada de propostas de região dos detectores de dois estágios. O YOLO11 é organizado em três partes: o backbone extrai características visuais da imagem, o neck combina essas características em diferentes escalas, e o head gera as caixas e as confianças sem depender de âncoras predefinidas.

Foram comparados dois tamanhos da família, ambos iniciados com pesos pré-treinados no conjunto COCO (transfer learning), o que permite aproveitar o conhecimento visual geral do modelo e treinar com poucas imagens:

Modelo	**Parâmetros**	**Custo (GFLOPs)**	**Papel no trabalho**
YOLO11n (nano)	2,6 milhões	6,4	Baseline leve, adequado a CPU e nuvem de baixo custo
YOLO11s (small)	9,4 milhões	21,4	Teste de maior capacidade do modelo

2.2 Roboflow

Plataforma usada para encontrar o conjunto de dados (Roboflow Universe), copiá-lo para o workspace da equipe (fork), dividir os conjuntos de treino, validação e teste, aplicar pré-processamento e augmentation, versionar o resultado e exportá-lo no formato YOLOv11. O download é feito por API dentro do notebook, com a chave guardada no gerenciador de segredos do Colab, fora do código.

2.3 Google Colab, Google Drive e OpenCV

O treino foi feito no Google Colab com GPU NVIDIA Tesla T4. Os resultados de cada treino (pesos, gráficos e métricas) são gravados diretamente no Google Drive, para que nada se perca se a sessão desconectar. A biblioteca OpenCV foi usada na demonstração em vídeo, para ler o vídeo quadro a quadro, desenhar as detecções e gravar o vídeo de saída.

2.4 Métricas de avaliação

- **IoU (Intersection over Union):** sobreposição entre a caixa prevista e a caixa anotada; define se uma detecção conta como acerto.
- **Precisão:** proporção das detecções do modelo que estavam corretas.
- **Recall:** proporção das regiões anotadas que o modelo encontrou.
- **mAP50:** precisão média considerando acerto quando o IoU é de pelo menos 0,5.
- **mAP50-95:** média do mAP para limiares de IoU de 0,5 a 0,95, mais exigente quanto à posição da caixa.
- **Acerto por imagem:** métrica definida pela equipe, que conta em quantas imagens com alagamento o modelo fez ao menos uma detecção com confiança de 0,5 ou mais. É a pergunta que o produto faz: esta foto mostra alagamento?

3. Metodologia

Passo 1 — Seleção do conjunto de dados. Foram avaliados conjuntos públicos do Roboflow Universe por quatro critérios: fotos tiradas ao nível da rua (como as que o morador envia), classe relacionada a água acumulada na via, licença aberta e quantidade de imagens. Um conjunto com 419 imagens foi descartado por conter fotos aéreas de drone com as classes building e vegetation, e outro por ter apenas 206 imagens. Foi escolhido o conjunto *water logging* (CityOps), com 199 imagens de ruas alagadas, uma classe (water_logging) e licença CC BY 4.0.

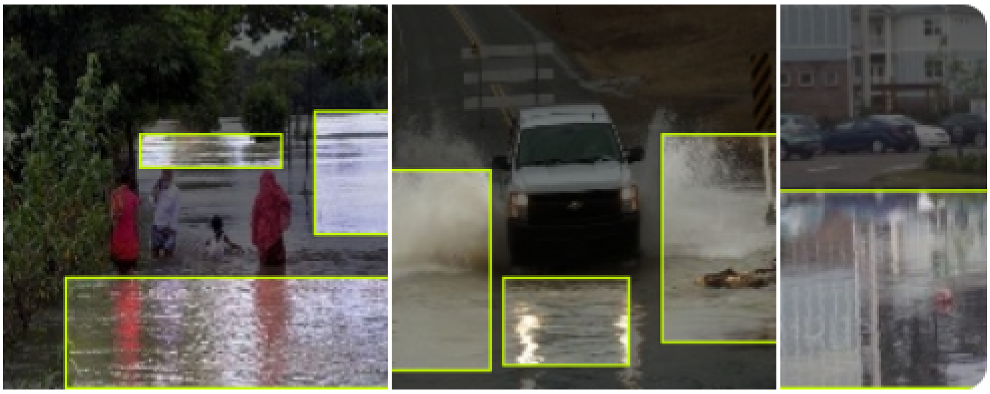

Figura 1 — Amostras do conjunto water logging (CityOps) com as anotações originais.

Passo 2 — Divisão dos dados. Após o fork para o workspace da equipe, as imagens foram divididas antes de qualquer augmentation, para que versões alteradas de uma mesma foto não aparecessem em treino e avaliação ao mesmo tempo.

Conjunto	Imagens originais	Após augmentation	Caixas anotadas
Treino	145	435	606
Validação	39	39	47
Teste	15	15	18

Passo 3 — Pré-processamento. Correção automática de orientação (auto-orient) e redimensionamento para 640 × 640 pixels, o tamanho de entrada usado no treino.

Passo 4 — Augmentation. Aplicada somente ao conjunto de treino, com saída de 3 versões por imagem: espelhamento horizontal, variação de brilho de –25% a +25% (simulando dias nublados e ensolarados) e desfoque de até 1 pixel (simulando fotos tiradas com o celular em movimento ou sob chuva).

Passo 5 — Treino. Dois treinos com a mesma base de dados e semente fixa (seed 42), permitindo comparar o efeito do tamanho do modelo. O parâmetro *patience* interrompe o treino quando o mAP de validação para de melhorar, evitando épocas desnecessárias.

Parâmetro	v1 (baseline)	v2
Modelo base	yolo11n.pt	yolo11s.pt
Épocas máximas	80	100
Patience	20	30
Tamanho de imagem	640	640
Batch	16	16
Tempo de treino (T4)	cerca de 8 min	cerca de 9 min

Passo 6 — Avaliação. Cada modelo foi avaliado de duas formas: pelas métricas padrão de detecção no conjunto de validação (mAP, precisão e recall) e pelo acerto por imagem nos conjuntos de validação e de teste, com limiar de confiança de 0,5.

Passo 7 — Demonstração em tempo real. O modelo escolhido foi aplicado a um vídeo de rua alagada, quadro a quadro. Em cada quadro, o sistema desenha as caixas detectadas, escreve na tela ALAGAMENTO DETECTADO ou Sem alagamento e mostra a taxa de quadros por segundo

(FPS), medindo o desempenho real do processamento.

Passo 8 — Integração com o MVP. Na arquitetura do AlertaBairro, o modelo escolhido (arquivo best.pt) é carregado pela API do produto (FastAPI). Quando o morador envia um relato com foto, a API executa a detecção e devolve se o alagamento foi confirmado, e esse resultado é gravado junto com o relato para orientar a moderação.

4. Resultados

4.1 Comparação entre os modelos

Métrica	v1 (YOLO11n)	v2 (YOLO11s)
mAP50	0,275	0,288
mAP50-95	0,133	0,137
Precisão	0,427	0,399
Recall	0,291	0,314
Acerto por imagem — validação	22/39 (56%)	17/39 (44%)
Acerto por imagem — teste	8/15 (53%)	8/15 (53%)
Parâmetros	2,6 milhões	9,4 milhões

O YOLO11s ganhou apenas 0,013 de mAP50, perdeu no acerto por imagem de validação e empatou no teste, sendo 3,6 vezes maior. **O modelo escolhido para o produto foi o YOLO11n**: entrega o mesmo resultado prático com um custo de processamento muito menor, o que reduz o custo da nuvem e o tempo de resposta da API.

4.2 Curvas de treino do modelo escolhido

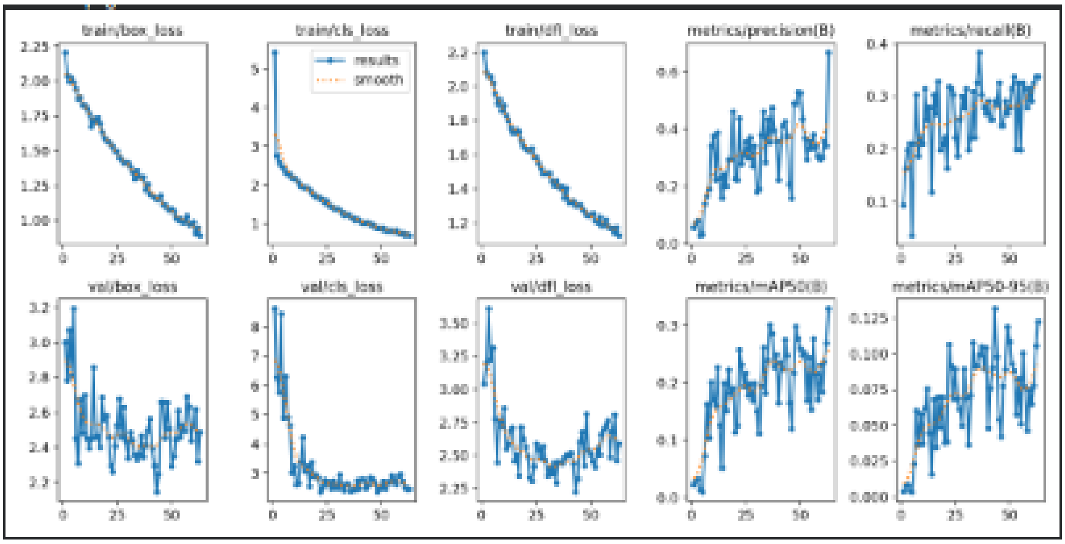

Figura 2 — Curvas de perda e métricas por época do YOLO11n (v1).

As perdas de treino caem de forma contínua durante todo o processo, enquanto as perdas de validação caem nas primeiras épocas e depois oscilam sem melhora clara. Esse padrão indica que o modelo continua aprendendo os exemplos de treino, mas generaliza pouco além deles, comportamento típico de um conjunto com poucas imagens originais (145).

4.3 Exemplos de detecção

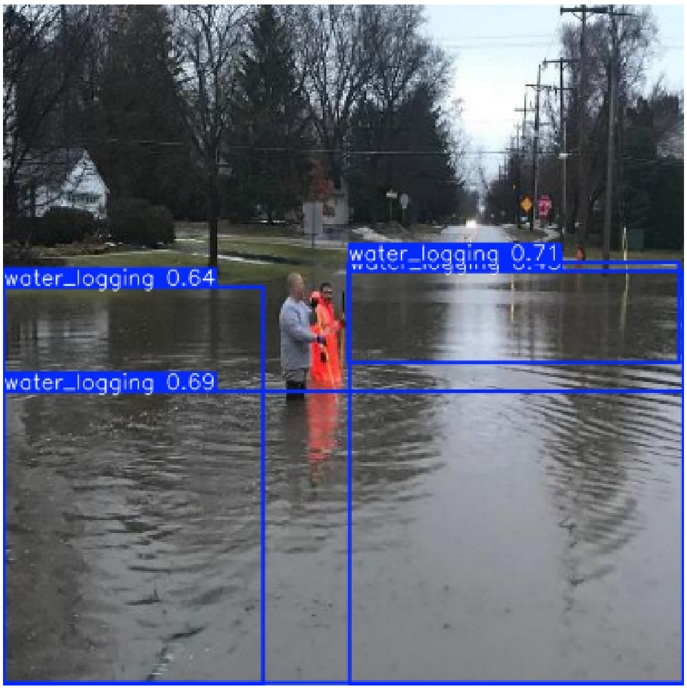

Figura 3 — Detecção em imagem de validação: três regiões de água acumulada, com confiança entre 0,64 e 0,71.

Na Figura 3, o modelo encontra a água corretamente, mas divide a mesma área alagada em várias caixas. Esse comportamento aparece em boa parte das predições e é discutido na seção 4.5.

4.4 Desempenho em vídeo (tempo real)

Indicador	Resultado
Quadros processados	1.772
Velocidade média	18,2 FPS (incluindo a gravação do vídeo de saída)
Quadros com alagamento sinalizado	92%
Tempo de inferência por imagem	cerca de 5 a 10 ms na GPU T4

A velocidade de 18,2 quadros por segundo é suficiente para operação em tempo real neste cenário, já que um alagamento muda em minutos, e não em frações de segundo. No uso principal do produto, a verificação de fotos, cada imagem é processada em milissegundos. Parte dos quadros sinalizados corresponde a alarmes falsos, discutidos na seção 4.5.

4.5 Erros e limitações observados

- **Caixas fragmentadas:** a água acumulada não tem forma definida, e cada anotador do conjunto recortou a mesma área de um jeito diferente. O mAP exige que a caixa prevista coincida com a anotada, então o modelo é penalizado mesmo quando encontra a água. Isso explica por que o mAP50 é baixo enquanto o vídeo mostra alagamento em 92% dos quadros.
- **Imagens sem detecção:** o modelo deixou de sinalizar alagamento em cerca de metade das imagens de validação e teste com o limiar de 0,5.
- **Falso positivo no vídeo:** quando a câmera sai da rua e mostra plantas ou uma parede, o aviso muda corretamente para sem alagamento. Porém, sobre uma tela de sombreamento turquesa, o modelo acusou água com confiança de 0,74 (Figura 4). Por isso, os 92% de quadros sinalizados incluem alguns alarmes falsos.

- **Ausência de exemplos negativos:** todas as imagens do conjunto contêm água, então o modelo nunca aprendeu como é uma superfície parecida com água que não é alagamento. O falso positivo da Figura 4 é consequência direta disso.

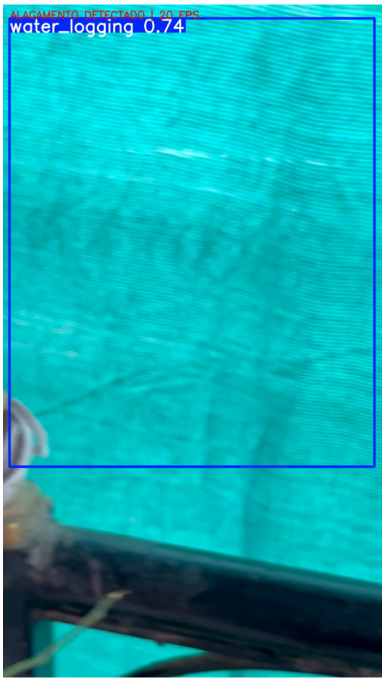

Figura 4 — Falso positivo: tela de sombreamento turquesa detectada como água (confiança 0,74).

- **Diferença de contexto:** as imagens públicas não são de São Paulo, cujas ruas, calçadas e veículos têm aparência diferente.

5. Conclusão

O trabalho entregou um detector de alagamento funcional e integrado à arquitetura do AlertaBairro, capaz de processar vídeo em tempo real a 18,2 quadros por segundo e de verificar fotos de relatos em milissegundos. O modelo escolhido, o YOLO11n, foi selecionado com base em evidência: o modelo 3,6 vezes maior não trouxe ganho prático.

A principal conclusão técnica é que **o limite atual está nos dados, e não no modelo**. Aumentar a capacidade da rede não melhorou o acerto por imagem, enquanto os erros observados apontam para a quantidade de imagens, a falta de exemplos negativos e o formato das anotações. Por isso, os próximos passos priorizam os dados:

- Coletar e anotar fotos de ruas alagadas de São Paulo, incluindo as enviadas pelos próprios moradores no MVP, com consentimento.
- Incluir imagens de ruas secas e apenas molhadas, sem anotação, para medir e reduzir alarmes falsos.
- Migrar de caixas para segmentação de instâncias (YOLO11-seg), que delimita o contorno real da água e permite estimar a área alagada.
- Borrar rostos e placas antes de armazenar as fotos dos relatos, em conformidade com a LGPD.

Mesmo com essas limitações, o componente já cumpre seu papel no produto: confirma automaticamente a maior parte dos relatos com alagamento visível e deixa para revisão humana apenas os casos incertos, reduzindo o trabalho de moderação justamente nos dias de chuva, quando ele é maior.

Referências

CITYOPS. *water logging Dataset*. Roboflow Universe, 2026. Licença CC BY 4.0. Disponível em: https://universe.roboflow.com/cityops/water-logging-go16i

JOCHER, G.; QIU, J. *Ultralytics YOLO11*. Ultralytics, 2024. Disponível em: https://github.com/ultralytics/ultralytics

BRADSKI, G. The OpenCV Library. *Dr. Dobb's Journal of Software Tools*, 2000.

LIN, T.-Y. et al. Microsoft COCO: Common Objects in Context. In: *European Conference on Computer Vision (ECCV)*, 2014.